

Anexo 1. Formulario a diligenciar semana tras semana y enviar junto con los pronósticos correspondientes.

1. ¿Cómo utilizaron los datos de la ventana a disposición? Detallen las características de las particiones usadas, el rango temporal considerado y cómo trataron las fechas sin medición (fines de semana y festivos).

Usamos la serie diaria del Banco de la República (15 de enero de 2008 al 2 de octubre de 2026), solo con información hasta el viernes 2 de octubre.

Para entrenar usamos los datos desde el 28 de mayo de 2021, cuando el MSCI COLCAP reemplazó al BVC COLCAP (unas 1.300 observaciones). Dejamos por fuera lo anterior porque es otro índice y para evitar la influencia de los datos faltantes de 2019 y la caída repentina de 2020 a causa de la pandemia.

De esa ventana, los últimos 100 bloques de 5 observaciones (500 en total) se usaron para validar. En cada bloque el modelo se ajusta con todo lo anterior y pronostica las 5 observaciones siguientes, que luego pasan al entrenamiento. Los bloques no se traslapan.

Los fines de semana y festivos no aparecen en la serie. Numeramos las observaciones en orden, así que $h = 1$ es siempre el siguiente día en que se calcula el índice.

2. Estrategia de validación (para cada pregunta, mencionen si se usaron variantes para algún modelo o si estas decisiones fueron iguales para todos):

¿Qué estrategia de ventana usarán? Expliquen

Probamos dos: una ventana expansible (entrena con todo lo disponible desde el 28 de mayo de 2021, así que crece en cada corte) y una ventana fija de 500 observaciones (solo los datos más recientes). Las comparamos en ETS y Drift. En Naive y sNaive daría lo mismo, porque solo usan los últimos datos.

Los resultados fueron muy parecidos (RMSE multi-paso entre 47,4 y 48,8). La ventana fija quedó apenas mejor en el Drift (47,4 frente a 47,5), y esa usamos para el pronóstico final.

¿Qué estrategia de muestreo usarán? Expliquen

Usamos un holdout repetido sin traslape: en vez de evaluar en una sola semana, hicimos 100 evaluaciones al final de la serie. En cada una, el punto de corte avanza 5 observaciones,

se pronostican las 5 siguientes y se comparan con lo real. Cada observación se usa una sola vez para evaluar.

Lo elegimos porque una sola semana puede no ser representativa y 100 repeticiones dan un error más estable, y porque los bloques de 5 imitan lo que haremos cada semana. No dejamos espacio entre entrenamiento y validación, porque en la práctica se pronostica con los datos hasta el viernes. Por los festivos, algunos cortes no caen en viernes, pero creemos que esto influye poco. Fue igual para todos los modelos.

¿Qué estrategia de recalibración usarán? Expliquen.

Comparamos dos opciones: recalibrar (reajustar el modelo desde cero en cada corte) y actualizar (mantener los parámetros del primer ajuste y solo sumar los datos nuevos). Lo probamos con el ETS, en ambas ventanas. En Naive y sNaive no aplica porque no tienen parámetros, y el Drift siempre se recalculó.

Actualizar dio menor RMSE (47,7 frente a 48,8 con ventana expansible; con la fija quedaron casi iguales, 47,7 y 47,8). La diferencia es pequeña, así que la tomamos como una ligera ventaja.

3. Por **cada modelo** considerado (incluidos los modelos base), mencionen algunas de sus características. Si entrenaron más de 5 modelos, reporten solo los hallazgos de los 5 con mejor desempeño

Modelo 1: Drift

Descripción general del modelo

Parte del último valor observado y le suma, por cada paso, el cambio promedio por observación de la ventana de entrenamiento, por lo que el resultado es una recta con poca pendiente.

Dentro de dicha estructura, ¿qué consideraron por parámetros y cómo los estimaron?

El único parámetro es la pendiente, que se calcula directamente como el cambio total de la ventana dividido entre el número de pasos.

Dentro de dicha estructura, ¿qué consideraron por hiperparámetros (si aplica)? ¿Cómo los estimaron?

No tiene. Lo que influye es la ventana de entrenamiento, y comparamos la expansible con la fija de 500 observaciones usando el RMSE de validación.

Modelo 2: ETS

Descripción general del modelo

Modelo de suavizamiento exponencial: actualiza el nivel de la serie (y, según la estructura, su tendencia) dando más peso a los datos recientes. Usamos la versión automática, que elige sola la estructura.

Dentro de dicha estructura, ¿qué consideraron por parámetros y cómo los estimaron?

Las constantes de suavizamiento (cuánto pesa lo reciente), el amortiguamiento si hay tendencia, y los valores iniciales, todos estos se estiman por máxima verosimilitud.

Dentro de dicha estructura, ¿qué consideraron por hiperparámetros (si aplica)? ¿Cómo los estimaron?

La estructura del modelo (tipo de error y de tendencia), que el procedimiento automático elige con el criterio AICc. También validamos el tipo de ventana y la recalibración.

Modelo 3: Naive

Descripción general del modelo

Modelo base: pronostica que todos los pasos serán iguales al último valor observado, este modelo sirve de referencia para ver si un modelo más complejo aporta algo.

Dentro de dicha estructura, ¿qué consideraron por parámetros y cómo los estimaron?

No tiene parámetros ya que depende solo del último dato.

Dentro de dicha estructura, ¿qué consideraron por hiperparámetros (si aplica)? ¿Cómo los estimaron?

No aplica.

Modelo 4: sNaive

Descripción general del modelo

Modelo base estacional: pronostica cada paso con el valor observado 5 observaciones atrás, es decir, el mismo día de la semana anterior, el objetivo era ver si hay un patrón semanal en el índice.

Dentro de dicha estructura, ¿qué consideraron por parámetros y cómo los estimaron?

No tiene parámetros ya que solo repite valores pasados.

Dentro de dicha estructura, ¿qué consideraron por hiperparámetros (si aplica)? ¿Cómo los estimaron?

El único dato fijado es el periodo de 5 observaciones, que corresponde a los 5 días de negociación de la semana (De lunes a viernes omitiendo festivos), este fue el peor modelo en la validación (RMSE 59,5), lo que indica que no hay un patrón semanal útil.

4. ¿Qué criterio o criterios tuvieron en cuenta para tomar la decisión de cálculo de los pronósticos? En particular, indiquen cómo seleccionaron los pronósticos finales entre los modelos considerados y cómo respetaron las restricciones de la semana correspondiente?

Elegimos el modelo con menor RMSE multi-paso en la validación, y revisamos también el RMSE de cada uno de los pasos.

Ganó el Drift con ventana fija (47,4), seguido muy de cerca por el Drift expansible (47,5), el ETS sin recalibrar y el Naive (47,7), mientras que el sNaive quedó claramente por debajo (59,5). Como las diferencias son pequeñas, las vemos como una ligera ventaja y no como una superioridad clara.

Con ese modelo hicimos el ajuste final con las últimas 500 observaciones hasta el viernes 2 de octubre y pronosticamos 5 pasos, del lunes 5 al viernes 9 de octubre.

Respetamos las restricciones de la semana usando solo modelos de suavizamiento, ETS y benchmarks, sin variables externas ni ARIMA, y sin datos posteriores al 2 de octubre.

5. En caso de que no sea la primera semana del proyecto, ¿qué cambios de estrategia resaltarían en relación con lo realizado la semana pasada? Expliquen qué motivó los cambios y qué evidencia utilizaron.

No aplica: es la primera semana.

6. ¿Qué archivos de datos, código y entorno de trabajo conservaron para poder reproducir los pronósticos entregados esta semana? Indiquen nombres de archivos, versión del código y, cuando sea pertinente, versiones de paquetes o del entorno.

Guardamos todo en la carpeta del proyecto, que también está en un repositorio en línea del grupo (github.com/JohanAv1018/Proyecto-Series-de-Tiempo-2026-1), con un archivo por semana:

- **Datos:** `colcap_semana1.xlsx`, la serie del Banco de la República hasta el 2 de octubre de 2026.
- **Código:** Informe Semana 1 Series de Tiempo Grupo 6.R, versión del 4 de octubre de 2026. Corre completo, desde la validación hasta el pronóstico final.
- **Entorno:** proyecto de RStudio (`Proyecto-Series-de-Tiempo-2026-1.Rproj`), con R [4.6.0] y los paquetes `fpp3` 1.0.3, `fable` 0.5.0, `tsibble` 1.2.0, `readxl` 1.4.5, `lubridate` 1.9.5 y `readr` 2.2.0.