Anexo 1. Formulario a diligenciar semana tras semana y enviar junto con los pronósticos correspondientes.

Grupo 6 — Semana 3

Ana Sofía Salazar Álvarez · Winston Obeymar Lucano Villota
Julian Camilo Tobo Tenen · Johan Steven Avilan Peñaloza

1. ¿Cómo utilizaron los datos de la ventana a disposición? Detallen las características de las particiones usadas, el rango temporal considerado y cómo trataron las fechas sin medición (fines de semana y festivos).

Usamos la serie diaria del Banco de la República (Índice COLCAP, dato diario) del 15 de enero de 2008 al 16 de octubre de 2026, solo con información hasta el viernes 16 de octubre. Verificamos la descarga con los valores de control del enunciado (17 de septiembre = 2521.85 y 18 de septiembre = 2548.22), que coincidieron.

Para entrenar usamos los datos desde el 28 de mayo de 2021, cuando el MSCI COLCAP reemplazó al BVC COLCAP (unas 1.314 observaciones). Dejamos por fuera lo anterior porque es otro índice y para evitar la influencia de los datos faltantes de 2019 y la caída repentina de 2020 a causa de la pandemia.

De esa ventana, validamos con bloques de 5 observaciones al final de la serie: en cada corte el modelo se ajusta con todo lo anterior y pronostica las 5 observaciones siguientes, que luego se comparan con lo real. Esta semana movimos el punto de corte observación por observación (522 cortes en total), buscando un error más estable que con los bloques no traslapados de la semana pasada.

Los fines de semana y festivos no aparecen en la serie. Numeramos las observaciones en orden, así que h = 1 es siempre el siguiente día en que se calcula el índice. Esta semana el lunes 19 no es festivo, de modo que se pronostican 5 pasos (lunes 19 a viernes 23 de octubre).

2. Estrategia de validación (para cada pregunta, mencionen si se usaron variantes para algún modelo o si estas decisiones fueron iguales para todos):

¿Qué estrategia de ventana usaron? Expliquen

Probamos dos, igual que la semana pasada y para todos los modelos: una ventana expansible (entrena con todo lo disponible desde el 28 de mayo de 2021, así que crece en cada corte) y una ventana fija de 500 observaciones (solo los datos más recientes). Los resultados fueron muy parecidos; la ventana fija quedó apenas mejor en el Drift (RMSE multi-paso 44,6 frente a 44,7), y esa usamos para el pronóstico final.

¿Qué estrategia de muestreo usaron? Expliquen

Usamos un holdout repetido por origen móvil: en vez de evaluar en una sola semana, hicimos 522 evaluaciones al final de la serie. En cada una el punto de corte avanza una observación, se pronostican las 5 siguientes y se comparan con lo real. Lo elegimos porque una sola semana puede no ser representativa y muchas repeticiones dan un error más estable, y porque los bloques de 5 imitan lo

que entregamos cada semana. No dejamos espacio entre entrenamiento y validación, porque en la práctica se pronostica con los datos hasta el viernes. Fue igual para todos los modelos.

¿Qué estrategia de recalibración usaron? Expliquen.

Recalibramos en cada corte: el modelo se reajusta desde cero con la ventana vigente antes de cada pronóstico, igual para todos los modelos. En Naive y medias móviles no aplica (no tienen parámetros) y el Drift siempre se recalcula. El código conserva además la opción de solo actualizar (mantener los parámetros del primer ajuste y sumar los datos nuevos), que no usamos para la selección final.

3. Por cada modelo considerado (incluidos los modelos base), mencionen algunas de sus características. Si entrenaron más de 5 modelos, reporten solo los hallazgos de los 5 con mejor desempeño.

Modelo 1: Drift (modelo elegido)

Descripción general del modelo

Parte del último valor observado y le suma, por cada paso, el cambio promedio por observación de la ventana de entrenamiento, por lo que el resultado es una recta con poca pendiente.

Dentro de dicha estructura, ¿qué consideraron por parámetros y cómo los estimaron?

El único parámetro es la pendiente, que se calcula directamente como el cambio total de la ventana dividido entre el número de pasos.

Dentro de dicha estructura, ¿qué consideraron por hiperparámetros (si aplica)? ¿Cómo los estimaron?

No tiene. Lo que influye es la ventana de entrenamiento, y comparamos la expansible con la fija de 500 observaciones usando el RMSE de validación.

Modelo 2: ETS (automático)

Descripción general del modelo

Modelo de suavizamiento exponencial: actualiza el nivel de la serie (y, según la estructura, su tendencia) dando más peso a los datos recientes. Usamos la versión automática, que esta semana eligió un ETS(M,N,N), es decir, sin tendencia ni estacionalidad; en la práctica se comporta casi como el Naive.

Dentro de dicha estructura, ¿qué consideraron por parámetros y cómo los estimaron?

La constante de suavizamiento del nivel (que resultó cercana a 1) y el valor inicial, estimados por máxima verosimilitud.

Dentro de dicha estructura, ¿qué consideraron por hiperparámetros (si aplica)? ¿Cómo los estimaron?

La estructura del modelo (tipo de error y de tendencia), que el procedimiento automático elige con el criterio AICc. También validamos el tipo de ventana y la recalibración.

Modelo 3: Naive

Descripción general del modelo

Modelo base: pronostica que todos los pasos serán iguales al último valor observado; sirve de referencia para ver si un modelo más complejo aporta algo.

Dentro de dicha estructura, ¿qué consideraron por parámetros y cómo los estimaron?

No tiene parámetros, ya que depende solo del último dato.

Dentro de dicha estructura, ¿qué consideraron por hiperparámetros (si aplica)? ¿Cómo los estimaron?

No aplica.

Modelo 4: ETS sobre transformaciones (log y Box-Cox)

Descripción general del modelo

Ajustamos el ETS sobre la serie transformada (logaritmo y Box-Cox) para estabilizar la varianza antes de modelar. La idea era ver si la transformación mejoraba el pronóstico; no lo hizo (Box-Cox 45,1 y log 45,8 de RMSE multi-paso, por debajo del Drift y el Naive).

Dentro de dicha estructura, ¿qué consideraron por parámetros y cómo los estimaron?

Los mismos del ETS (constante de suavizamiento y valor inicial), estimados por máxima verosimilitud sobre la escala transformada.

Dentro de dicha estructura, ¿qué consideraron por hiperparámetros (si aplica)? ¿Cómo los estimaron?

El parámetro de transformación: en Box-Cox el λ, estimado automáticamente por el método de Guerrero; en el logaritmo, $\lambda = 0$ fijo.

Modelo 5: Medias móviles

Descripción general del modelo

Modelo base de promedio local: pronostica el promedio de las últimas observaciones (probamos ventanas de 20 y 60). El objetivo era ver si suavizar con un promedio reciente ayudaba; fue de los peores (RMSE 79,2 con ventana 20 y 119,5 con 60), lo que confirma que promediar el pasado reciente pierde el nivel actual de la serie.

Dentro de dicha estructura, ¿qué consideraron por parámetros y cómo los estimaron?

No tiene parámetros que estimar: solo promedia los valores de la ventana.

Dentro de dicha estructura, ¿qué consideraron por hiperparámetros (si aplica)? ¿Cómo los estimaron?

El tamaño de la ventana del promedio (20 o 60 observaciones), que comparamos con el RMSE de validación.

4. ¿Qué criterio o criterios tuvieron en cuenta para tomar la decisión de cálculo de los pronósticos? En particular, indiquen cómo seleccionaron los pronósticos finales entre los modelos considerados y cómo respetaron las restricciones de la semana correspondiente.

Elegimos el modelo con menor RMSE multi-paso en la validación, y revisamos también el RMSE de cada paso. Ganó el Drift con ventana fija (44,6), seguido muy de cerca por el Drift expansible (44,7), el Naive y el SES (45,0) y el ETS sobre Box-Cox (45,1), mientras que las medias móviles quedaron claramente por debajo. Como las diferencias entre los primeros son pequeñas, las vemos como una ligera ventaja y no como una superioridad clara.

Con ese modelo hicimos el ajuste final con la ventana hasta el viernes 16 de octubre y pronosticamos 5 pasos, del lunes 19 al viernes 23 de octubre:

Fecha	Paso	Modelo	Pronóstico (puntos)
lunes 19 oct	h = 1	RW con deriva	2567.32
martes 20 oct	h = 2	RW con deriva	2568.35
miércoles 21 oct	h = 3	RW con deriva	2569.39
jueves 22 oct	h = 4	RW con deriva	2570.42
viernes 23 oct	h = 5	RW con deriva	2571.46

Respetamos las restricciones de la semana: aunque a partir de esta semana ya se permiten modelos ARMA, ARIMA y SARIMA, decidimos no usarlos, y nos quedamos con modelos de suavizamiento, ETS y benchmarks, sumando transformaciones (log y Box-Cox) y medias móviles. No usamos variables externas ni datos posteriores al 16 de octubre.

5. En caso de que no sea la primera semana del proyecto, ¿qué cambios de estrategia resaltarían en relación con lo realizado la semana pasada? Expliquen qué motivó los cambios y qué evidencia utilizaron.

Resaltamos dos cambios. Primero, ampliamos el conjunto de modelos con transformaciones (logaritmo y Box-Cox) y medias móviles, aprovechando que el profesor autorizó el uso de transformaciones; la evidencia de validación mostró que ninguna mejora al Drift, así que las reportamos pero no las elegimos. Segundo, refinamos la validación: pasamos de bloques no traslapados (avanzando de 5 en 5) a origen móvil observación por observación (522 cortes), para obtener un error más estable.

Con estos cambios mantuvimos el RW con deriva como pronóstico, pero ahora con más respaldo: comprobamos que ni las transformaciones ni las medias móviles mejoran a un modelo simple en esta serie.

6. ¿Qué archivos de datos, código y entorno de trabajo conservaron para poder reproducir los pronósticos entregados esta semana? Indiquen nombres de archivos, versión del código y, cuando sea pertinente, versiones de paquetes o del entorno.

Guardamos todo en la carpeta del proyecto, que también está en un repositorio en línea del grupo (github.com/JohanAv1018/Proyecto-Series-de-Tiempo-2026-1), con un archivo por semana:

Datos: COLCAP_datos_usados_Semana3_corte_2026-10-16.csv (serie limpia del nivel diario) y la descarga original del Banco de la República, la serie del Índice COLCAP hasta el 16 de octubre de 2026.

Código: Informe Semana 3 Series de Tiempo Grupo 6.R, versión del 18 de octubre de 2026. Corre completo, desde la validación hasta el pronóstico final.

Entorno: proyecto de RStudio (Proyecto-Series-de-Tiempo-2026-1.Rproj), con R 4.6.1 y los paquetes fpp3 1.0.3, fable 0.5.0, tsibble 1.2.0, feasts 0.5.0, readxl 1.5.0.1, purrr 1.2.2 y readr 2.2.0.