Anexo 1. Formulario a diligenciar semana tras semana y enviar junto con los pronósticos correspondientes.

Grupo 6 - Semana 5

Ana Sofía Salazar Álvarez · Winston Obeymar Lucano Villota
Julian Camilo Tobo Tenen · Johan Steven Avilan Peñaloza

1. ¿Cómo utilizaron los datos de la ventana a disposición? Detallen las características de las particiones usadas, el rango temporal considerado y cómo trataron las fechas sin medición (fines de semana y festivos).

Se usó la serie diaria del Índice COLCAP del catálogo del Banco de la República, restringida al período MSCI COLCAP: del 28 de mayo de 2021 al 30 de octubre de 2026 (1.324 observaciones).
Los datos anteriores corresponden al bvc COLCAP, que tenía otra metodología, y se decidió omitirlos tras verificar en la semana anterior que incluirlos no reducía el error.
La serie se indexó por días de negociación: dos días hábiles consecutivos son pasos consecutivos y no se imputaron fines de semana ni festivos, porque en ellos el índice no existe.
Los modelos se ajustaron sobre el logaritmo del nivel. Para validar se usaron particiones de origen móvil con bloques de prueba de 4 días hábiles (pues la actual semana tiene un día festivo el lunes 2 de Noviembre) y un entrenamiento mínimo de 250 observaciones.
Las fechas pronosticadas son los 4 días hábiles siguientes al último dato (del martes 3 al viernes 6 de noviembre).

2. Estrategia de validación (para cada pregunta, mencionen si se usaron variantes para algún modelo o si estas decisiones fueron iguales para todos):

La estrategia de validación fue la misma para todos los modelos.

Ventana. Probamos dos tipos de ventanas, la ventana expansiva, que usa todos los datos disponibles hasta cada punto de corte, y ventanas fijas de 250 y 500 días, que solo usan los datos más recientes, de las dos, decidimos quedarnos con la expansiva.
Con esta, el ARIMA(2,1,0) obtuvo un error ligeramente menor que el naive en los horizontes evaluados, mientras que con las ventanas fijas a 4 días su error quedó igual o un poco por encima del naive. En ningún caso las diferencias fueron significativas, así que elegimos la ventana expansiva por ser la que usa toda la información disponible y la que dio resultados más consistentes.

Muestreo. Para evaluar los modelos se simularon pronósticos pasados y los comparamos con las observaciones que teníamos de esos periodos simulados.
Los datos se dividieron en bloques de 4 días hábiles, igual al horizonte de pronóstico de esta semana, usando al menos 250 observaciones para estimar el modelo antes del primer

bloque y donde los bloques no se solaparan entre si.
Se probaron dos variantes de esta partición. En la primera, el bloque de prueba comienza justo después del último dato de entrenamiento (267 pruebas). En la segunda se dejan 4 días hábiles sin usar entre el entrenamiento y el bloque de prueba (134 pruebas).
En ambas variantes, cada modelo se comparó con el naive a 1, 2 y 4 días, a partir de su error de pronóstico y de la prueba de Diebold-Mariano, que indica si la diferencia entre dos modelos es real o puede deberse al azar.

3. Por **cada modelo** considerado (incluidos los modelos base), mencionen algunas de sus características. Si entrenaron más de 5 modelos, reporten solo los hallazgos de los 5 con mejor desempeño

Modelo 1: ARIMA(2,1,0) con deriva sobre log(COLCAP)

Descripcion general: Modelo para el cambio diario del índice en logaritmos. Supone que ese cambio depende un poco de los cambios de los dos días anteriores y que, en promedio, el índice tiene una tendencia diaria constante (la deriva).
Parametros: Dos coeficientes que miden cuánto pesan los dos días anteriores y la deriva, estimados por máxima verosimilitud.
Hiperparametros: El orden se fijó a priori, porque los cambios diarios muestran autocorrelación significativa en los rezagos 1 y 2. Se trabaja sobre el logaritmo del índice y con una diferenciación, según las pruebas ADF y KPSS.
Los residuos no muestran autocorrelación (Ljung-Box, $p = \mathbf{0.36}$).

Modelo 2: ARIMA(0,1,2) con deriva sobre log(COLCAP)

Descripcion general: Parecido al anterior, pero en lugar de usar los cambios de los días previos, corrige el pronóstico con los dos errores de pronóstico más recientes.
Parametros: Dos coeficientes sobre esos errores y la deriva, estimados por máxima verosimilitud. Los coeficientes resultaron pequeños (0,087 y 0,046), por lo que el modelo se aleja poco del paseo aleatorio.
Hiperparametros: El orden lo eligió `auto.arima` por AICc, con búsqueda exhaustiva sobre el logaritmo del índice y una diferenciación.
Los residuos no muestran autocorrelación (Ljung-Box, $p = 0{,}41$).

Modelo 3: ETS

Descripcion general: Suavizamiento exponencial: el pronóstico se construye con un promedio ponderado de los datos pasados, que da más peso a los más recientes. Con todos los datos, el modelo elegido produce un pronóstico plano, igual al del naive.
Parametros: La constante de suavizamiento y el nivel inicial, estimados por máxima verosimilitud.
Hiperparametros: La forma del modelo (con o sin tendencia) se elige automáticamente por AICc. No incluye estacionalidad.

Modelo 4: Paseo aleatorio con deriva

Descripcion general: Toma el último valor observado y le suma una pendiente constante cada día.
Parametros: La pendiente, que es el cambio diario promedio de la muestra.
Hiperparametros: Ninguno, aparte de la ventana de entrenamiento.

Modelo 5: Naive

Descripcion general: El pronóstico es el último valor observado, repetido para todos los días.
Parametros: Ninguno.
Hiperparametros: Ninguno.

4. ¿Qué criterio o criterios tuvieron en cuenta para tomar la decisión de cálculo de los pronósticos? En particular, indiquen cómo seleccionaron los pronósticos finales entre los modelos considerados y cómo respetaron las restricciones de la semana correspondiente?

Criterios. El criterio principal fue el RMSE a 1 y a 4 días, comparado con el del naive. Con la ventana expansiva, que fue la que elegimos, el ARIMA(2,1,0) con deriva tuvo el menor RMSE de los cinco modelos en ambos horizontes (18.63 frente a 18.93 del naive a 1 día, y 39.67 frente a 39.82 a 4 días), aunque con ventanas fijas esa ventaja no se mantiene. Ningún modelo superó al naive de forma significativa según la prueba de Diebold-Mariano, por lo que reconocemos que la ventaja es pequeña. Lo escogimos también por ser un modelo sencillo, con un orden fijado de antemano, y porque sus residuos no muestran autocorrelación (Ljung-Box, $p = 0{,}36$).

Restricciones respetadas. Solo se usó la serie del COLCAP, con información hasta el cierre del viernes 30 de octubre de 2026, sin datos posteriores. Aunque esta semana se permitían variables exógenas, decidimos no usarlas. Los pronósticos son puntuales para los 4 días hábiles de la semana (del martes 3 al viernes 6 de noviembre), y el lunes 2,

festivo, no se pronostica.

5. En caso de que no sea la primera semana del proyecto, ¿qué cambios de estrategia resaltarían en relación con lo realizado la semana pasada? Expliquen qué motivó los cambios y qué evidencia utilizaron.

Resaltamos tres cambios respecto a la semana anterior.
Primero, redujimos los modelos candidatos de 15 a 5 (naive, drift, ETS, ARIMA automático y ARIMA(2,1,0)). Ya que encontramos que la semana pasada las combinaciones y los híbridos no mejoraron los resultados, porque los errores de los modelos estaban muy correlacionados (entre 0.993 y 0.999), y el SARIMA no encontró efecto del día de la semana. Con menos modelos también hay menos comparaciones, es más fácil distinguir una mejora real del azar y es más rápida la ejecución del código.
Segundo, cambiamos el modelo entregado: de un ARIMA(1,1,0) con deriva a un ARIMA(2,1,0) con deriva, también sobre el logaritmo y con ventana expansiva. Con los datos actualizados, la búsqueda exhaustiva de `auto.arima` ya no eligió un modelo de un solo rezago, sino uno de dos (ARIMA(0,1,2)). Además, con la ventana expansiva el ARIMA(2,1,0) tuvo el menor RMSE de los cinco modelos a 1 y a 4 días, y sus residuos no mostraron autocorrelación.
Tercero, adaptamos la validación al horizonte de esta semana. Como el lunes 2 de noviembre es festivo, pronosticamos 4 días hábiles en lugar de 5, y por eso los bloques de prueba son de 4 días y los horizontes evaluados son 1, 2 y 4. Mantuvimos la ventana expansiva y la prueba de Diebold-Mariano contra el naive. Aunque esta semana se permitían variables exógenas, decidimos no usarlas.

6. ¿Qué archivos de datos, código y entorno de trabajo conservaron para poder reproducir los pronósticos entregados esta semana? Indiquen nombres de archivos, versión del código y, cuando sea pertinente, versiones de paquetes o del entorno.

Guardamos todo en la carpeta del proyecto, que también está en el repositorio en línea del grupo (`github.com/JohanAv1018/Proyecto-Series-de-Tiempo-2026-1`), con archivos por semana:
Datos: `colcap_semana5.xlsx`, con la descarga original del Banco de la República de la serie del Índice COLCAP hasta el 30 de octubre de 2026. El código filtra el período MSCI, desde el 28 de mayo de 2021 (1.324 observaciones).
Código: `Informe Semana 5 Series de Tiempo Grupo 6.R`. Corre completo, desde la carga de datos y la identificación hasta la validación y el pronóstico final, y muestra las tablas de validación y de pronósticos en la consola.
Entorno: se mantuvo el de la semana anterior, R 4.3.1 (2023-06-16, ucrt) en Windows 11 x64 con los paquetes `forecast` 9.0.2, `tseries` 0.10-63, `dplyr` 1.1.4, `readxl` 1.4.3,

`lubridate` 1.9.4, `ggplot2` 4.0.3 y `pacman` 0.5.1; dependencias relevantes: `urca` 1.3-4, `zoo` 1.8-13 y `fracdiff` 1.5-4. Ninguno de los métodos usa componentes aleatorios, por lo que los resultados se reproducen sin fijar semilla.